实验报告

实验目的

根据论文《A Fast and Cost-Efficient Hashing Index Scheme for Cloud Storage Systems》提出的一种高性能的哈希索引结构,以及论文中给出的相关开源代码和使用的数据集,重现实验,验证这种哈希结构相对于传统哈希的改进和性能上的提升,从而对该论文有更好的理解。

实验环境

实验开展的环境是: Ubuntu 16.04 LTS Intel i5 7200U 2.5GHz 4-core CPU 16GB DDR4 RAM 网卡带宽: 1GBps 500GB 硬盘

哈希函数相互独立,且同分布(均匀分布)

实验原理

Cuckoo Hash

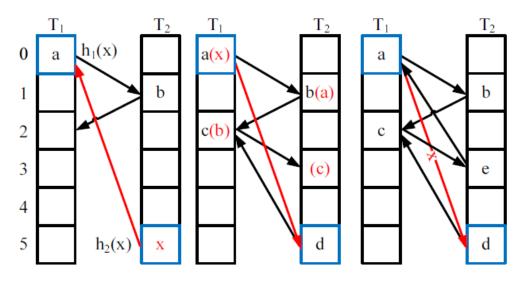
散列表是一种查询高效的数据结构,它通过键值与逻辑存储位置的对应关系,来解决存储方案从而降低查询复杂度,使之达到 O(1)的水平。但是哈希冲突会逐渐导致查询性能的下降,故,解决冲突或者降低冲突的发生概率,是一个很重要的研究话题。

CuckooHash 是一个动态化的静态字典,它以多散列方式解析哈希冲突。 传统 CuckooHash 的设计具有两个哈希表,两个哈希函数。一个插入的元素, 分别在两个哈希表中对应有一个实际存储位置和一个备用位置,元素在插入的时候,如果一个哈希函数得到的存储位置发生了冲突,就用另一个哈希函数。两个

CuckooHash 的逻辑结构可以表述为一个有向图。其中,每一条边代表一个插入的元素,这条边连接的两端,起点表示元素的实际存储位置,终点表示该元

素的备用存储位置。

下图是向 CuckooHash 结构的散列表插入元素的演变过程示意图:



- (a) Vacant bucket(s). (b) Finite kicks. (c) An endless loop.

一般而言,如果两个哈希函数计算出来的存储位置都是空闲可用的,那么随 机取一个(还是取第一个)作为实际存储位置,另一个作为备用位置;如果其中 一个被占用(即发生冲突),另一个空闲可用,那么,空闲的作为实际存储位置, 被占用的作为备用位置,此时,在有向图中,这个元素所对应的边,就由空闲位 置(实际存储位置)指向被占用位置(备用位置):如果两个哈希函数计算出来 的位置都被占用,那么就要随机游走,并进行踢出操作(调解),将已经占用的 元素,根据边的指向,踢出到备用空间,迭代这个操作,直至寻找到空闲可用的 位置。但是这样就会面临一个问题:在闭环的有向图当中游走,陷入死循环。 CuckooHash 必须寻求一个再哈希操作。

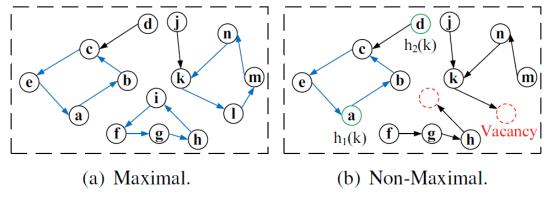
Pseudoforest

Pseudoforest Theory (伪森林理论): 一个 pseudoforest 在图论中是一个无向 图,子图的每个连通分量中最多只能有一个环,而且这个子图的所有权值之和最 大。具有这样的特点:这样的无向图中的边的数目不多于顶点数。

- 1、伪森林的定义
 - (a) 一个无向图;
 - (b) 它的所有连通分量最多只有一个环;
 - (c) 伪森林的大小取决于图中所有边的边权之和。

2、最大子图

顶点数目瞪圆边数目,它包含一个环,伪森林中任何子图都是最大子图 一个有向伪森林如下图所示:



有向图的伪森林中,每个顶点至少有一个出度:

SmartCuckoo Hash

传统的哈希选择一个候选位置作为插入位置,而不考虑该处是否会导致闭环 回路,新设计的方案,通过追踪子图的状态去预测插入。

新的方案具有以下特点:

一个元素的插入位置必须属于一个子图,该子图中包含出度为 0 的顶点; 检测空缺是 cuckoo hash 很关键的操作;

每个 bucket 最多存储一个元素,每个元素都有唯一一个备份位置;

哈希表中的个数总是不多于 bucket 的个数,而有向图中顶点的个数也不少于边数,因此,一个子图中最多存在一个闭环,故,用有向图来描述元素位置 SmartCuckoo 是一个有向伪森林;

当一个非最大有向子图插入一个元素时,它将会存储在一个候选位置,一个被踢出的元素存储在有向 cuckoo 路径的最后一个顶点

向一个最大有向伪森林插入元素,不可避免会产生闭环回路

有向伪森林中,除了位于非最大子图有向路径的末端的空间 bucket 是一个出度为 0 之外,其余顶点都有一个出度

最大有向伪森林中,每一个顶点都有1的出度,没有顶点能作出踢出操作之后的元素存储目标,也即闭环发生。

因为只有非最大子图才含有空闲 bucket,故,一次成功的插入,取决于元素的候选位置是否有一个(以上)在非最大子图中。

实验内容

环境准备

1、哈希算法的代码实现

SmartCuckoo 源码

https://github.com/syy804123097/SmartCuckoo

libcuckoo 源码

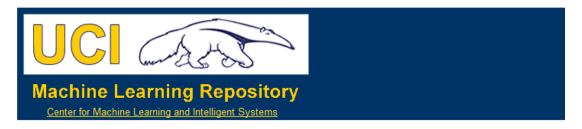
https://github.com/efficient/libcuckoo

2、数据集的准备

(1) Traces and Snapshots Public Archive.

Release Number	Release Date	MacOS dates covered	Homes dates covered	
1	July 2014	From June 2011 to May 2014	From September 2011 to May 2014	
2	December 2016	From May 2014 to May 2016	From August 2014 to November 2014	
1+2 Updated *	December 2017	From June 2011 to May 2016	From September 2011 to November 2014	

(2) Bag-of-words data set.



Bag of Words Data Set

Download: Data Folder, Data Set Description

Abstract: This data set contains five text collections in the form of bags-of-words.

Data Set Characteristics:	Text	Number of Instances:	8000000	Area:	N/A
Attribute Characteristics:	Integer	Number of Attributes:	100000	Date Donated	2008-03-12
Associated Tasks:	Clustering	Missing Values?	N/A	Number of Web Hits:	229348

运行代码

编译 libcuckoo 的测试代码

```
root@lxb-laptop:~/smartcuckoo/libcuckoo/build# cmake -DCMAKE_INSTALL_PREFIX=../i
nstall -DBUILD_EXAMPLES=1 -DBUILD_TESTS=1 ..
-- The C compiler identification is GNU 4.8.4
-- The CXX compiler identification is GNU 4.8.4
-- Check for working C compiler: /usr/bin/cc
-- Check for working C compiler: /usr/bin/cc -- works
-- Detecting C compiler ABI info
-- Detecting C compiler ABI info - done
-- Detecting C compile features
-- Detecting C compile features - done
-- Check for working CXX compiler: /usr/bin/c++
-- Check for working CXX compiler: /usr/bin/c++ -- works
-- Detecting CXX compiler ABI info
-- Detecting CXX compiler ABI info - done
-- Detecting CXX compile features
-- Detecting CXX compile features - done
-- Looking for include file pthread.h
-- Looking for include file pthread.h - found
-- Looking for pthread create

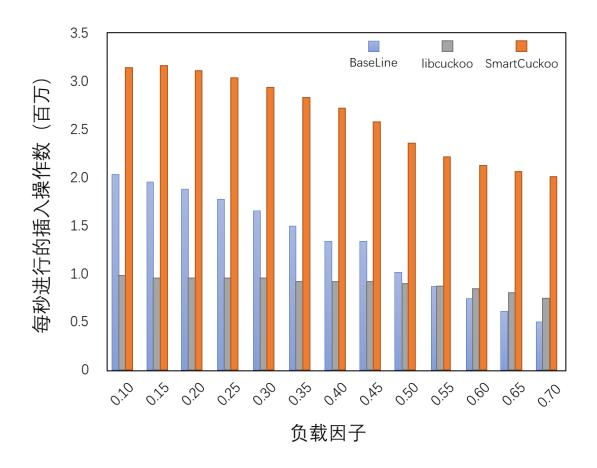
    Looking for pthread_create - not found

-- Check if compiler accepts -pthread
-- Check if compiler accepts -pthread - yes
-- Found Threads: TRUE
-- Configuring done
```

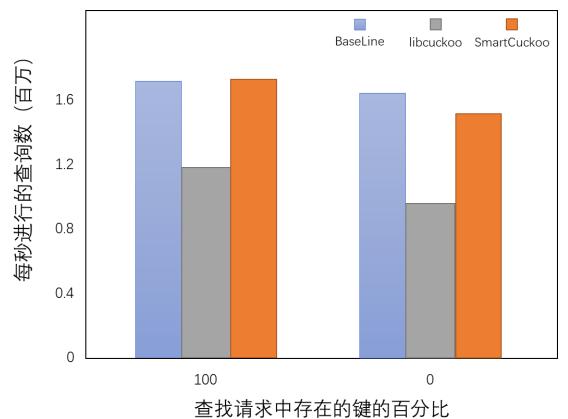
编译 SmartCuckoo 的测试代码

实验数据

插入随机数



随机数的查找吞吐量



实验结论

快速高效的查询服务是云存储系统的重要组成部分。由于开放寻址的显著特点,CuckooHash 支持快速查询。然而,它遇到了潜在的问题,在项目插入无限循环。SmartCuckoo 是一个新的高效的哈希方案,它的提出,在哈希表中跟踪项目位置,通过使用有向图伪森林来表示散列关系,SmartCuckoo 可以准确预测 Cuckoo 操作和死循环状态,进一步避免随机游走的过程陷入一个无限循环,而是控制在一个 pseudoforest 最大子图。